

# 基於連續時間量子行走的蛋白質別構口袋預測

Cleveland Clinic Challenge 2026 — 技術報告

Leo

2026 年 6 月

## 目录

|                                                   |    |
|---------------------------------------------------|----|
| 1 問題定義                                            | 1  |
| 2 核心假設與整體流程                                       | 2  |
| 3 GVP-GNN 架構                                      | 3  |
| 4 損失函數演進                                          | 4  |
| 5 ENAQT 失敗分析                                      | 4  |
| 6 混合模型 (Hybrid)                                   | 5  |
| 7 實驗結果                                            | 6  |
| 8 難以成藥蛋白質的三層驗證框架                                  | 6  |
| 9 與 PocketMiner 的關聯及提議流程                          | 7  |
| 10 为什么 $T \rightarrow \infty$ 連通性損失失效——量子行走根本原因分析 | 8  |
| 11 新架構提案: LLM + PDB + GVP-GNN + CTQW              | 9  |
| 12 評估框架: AUPRC 與多指標分析                             | 10 |
| 13 結論                                             | 11 |

## 1 問題定義

給定蛋白質的 apo (未結合) 晶體結構，預測哪些殘基構成別構口袋 (allosteric pocket) ——一個能在不阻擋活性位點的情況下，遠程調節蛋白質功能的結合位點。

挑戰蛋白質：

| 蛋白質            | Apo PDB | 別構配體              | 相關性                  |
|----------------|---------|-------------------|----------------------|
| KRAS G12C      | 4OBE    | Sotorasib (6OIM)  | 致癌 RAS, switch-II 口袋 |
| BCR-ABL1       | 1OPL    | Asciminib (5MO4)  | 白血病激酶, 肉豆蔻鹽口袋        |
| Cardiac Myosin | 5TBY    | Mavacamten (6C1H) | 肥厚型心肌病               |

BCR-ABL1 的肉豆蔻鹽口袋距 ATP 結合活性位點超過 30 Å，使用傳統擴散方法無法觸及。

## 2 核心假設與整體流程

**核心假設：**量子行走比傳統隨機行走更能捕捉蛋白質中的遠程通訊，原因是量子干涉使訊號可以同時沿多條路徑傳播，對長距離口袋（如 BCR-ABL1）尤其有利。




圖 1: 整體預測流程。GVP-GNN 編碼器同時輸出哈密頓量  $H$ （用於 CTQW）和直接分類 logits（用於 BCE 損失）。推論時，混合模型以可調參數  $\beta$  合并兩種訊號。

### 3 GVP-GNN 架構

Geometric Vector Perceptron (GVP) [1] 是一種幾何等變圖神經網路，可同時處理純量特徵與向量特徵。

**圖的建構：**以 12 Å 截止距離建立  $C\alpha$  接觸圖；每個節點帶有 24 維純量特徵（化學性質）和 1 組 3D 向量特徵（局部幾何）；每條邊帶有 24 維純量特徵（距離、方向）。




圖 2: GVP-GNN 架構。4 層訊息傳遞後，節點嵌入  $s \in \mathbb{R}^{N \times 64}$  分叉至兩個輸出頭：H 頭產生 CTQW 哈密頓量；分類頭產生 BCE logits。

**CTQW 連通性矩陣 (communicability):**

$$C[i, j] = \sum_k |V_{ik}|^2 |V_{jk}|^2$$

其中  $V$  为  $H$  的特徵向量矩陣。此式为  $T \rightarrow \infty$  時量子行走的時間平均，透過單次 `eigh` 呼叫即可封閉形式計算。

## 4 損失函數演進




圖 3: 從 v1 (稀疏  $H$ ) 到基准模型 (BCE) 的模型演進與命中率 (hit rate) 變化。圓形徽章顯示各模型在三個挑戰蛋白質上的平均命中率。

| 模型版本     | 主要改動                              | 損失類型      | 命中率          |
|----------|-----------------------------------|-----------|--------------|
| CTQW v1  | 稀疏 $H$ (相鄰矩陣)                     | 連通性損失     | 0.533        |
| CTQW v2  | 稠密 $H$ ( $hh^T/K + \text{diag}$ ) | 連通性損失     | 0.800        |
| CTQW v3  | 稠密 $H$ + ENAQT 速率                 | ENAQT 損失  | 0.800        |
| CTQW v4  | 每蛋白質可學習 $\gamma$                  | ENAQT 損失  | 0.800        |
| Hybrid   | 共享編碼器 + 兩個輸出頭                     | BCE + 連通性 | <b>0.867</b> |
| Baseline | 純 GVP 分類                          | BCE       | 0.933        |

表 1: 各模型結果比較。黃色高亮為本研究提出之最佳量子增強方法。

**基准模型 (0.933) 勝出的原因:** BCE 損失對  $N$  個殘基提供密集梯度訊號；連通性損失每步僅產生 1 個純量梯度，訊號密度相差  $N$  倍 ( $N \approx 200-500$ )。

## 5 ENAQT 失敗分析

環境輔助量子輸運 (ENAQT, Haken–Strobl–Reineker 速率):

$$k_{ij} = \frac{2|H_{ij}|^2 \gamma}{\gamma^2 + (H_{ii} - H_{jj})^2}$$

此公式無需特徵分解，梯度路徑更直接： $\mathcal{L} \rightarrow p \rightarrow W \rightarrow K \rightarrow H_{ij}$ 。




圖 4: ENAQT 失敗根本原因：近口袋蛋白質（KRAS、Cardiac Myosin）需要高去相干速率（ $\gamma \approx 0.8$ ），遠口袋蛋白質（BCR-ABL1）需要近相干極限（ $\gamma \approx 0.05$ ）。共享的  $\gamma$  頭學到折衷值  $\gamma \approx 0.17$ ，導致兩者表現均差。

## 6 混合模型 (Hybrid)




圖 5: 混合模型架構。訓練時： $\mathcal{L} = \mathcal{L}_{\text{BCE}} + \lambda \cdot \mathcal{L}_{\text{comm}}$ 。推論時：scores =  $\sigma(\text{logits}) + \beta \cdot C[\text{active} \rightarrow i]$ 。

**設計原理：**BCE 提供密集梯度使模型學習別構位點的化學特徵；CTQW 連通性在推論時加強那些既具化學相似性、又能從活性位點量子可達的殘基。

$\beta$  掃描結果：

| $\beta$     | KRAS | BCR-ABL1 | Cardiac Myosin |
|-------------|------|----------|----------------|
| 0.0 (純 BCE) | 1.00 | 0.60     | 0.80           |
| 0.2         | 1.00 | 0.60     | 1.00           |
| 0.5         | 1.00 | 0.60     | 1.00           |
| 1.0         | 1.00 | 0.60     | 0.80           |

**表 2:**  $\beta$  對各蛋白質命中率的影響。BCR-ABL1 停留於 0.60，原因是最佳 checkpoint 在第 20 epoch ( $H$  尚未完全收斂)。

## 7 實驗結果

| 模型                        | KRAS        | BCR-ABL1    | Cardiac     | 平均           |
|---------------------------|-------------|-------------|-------------|--------------|
| CTQW v1 (稀疏 $H$ )         | 0.80        | 0.40        | 0.40        | 0.533        |
| CTQW v2 (稠密 $H$ )         | 1.00        | 0.80        | 0.60        | 0.800        |
| CTQW v3 (ENAQT)           | 0.80        | 0.80        | 0.80        | 0.800        |
| CTQW v4 (per- $\gamma$ )  | 1.00        | 0.80        | 0.60        | 0.800        |
| Hybrid ( $\beta = 0.5$ )  | 1.00        | 0.60        | 1.00        | 0.867        |
| <b>Baseline (GVP BCE)</b> | <b>1.00</b> | <b>1.00</b> | <b>0.80</b> | <b>0.933</b> |

**表 3:** 三個挑戰蛋白質上的命中率 (Top-5, 距離閾值 8 Å)。黃色行為最佳量子增強結果。

**關鍵發現：**

- GVP BCE 基準達到 0.933，超越所有 CTQW 變體，原因是密集梯度訊號。
- 混合模型 (0.867) 使 Cardiac Myosin 從 0.60 提升至 1.00，顯示 CTQW 對近距離口袋有效。
- BCR-ABL1 在混合模型中停留於 0.60 (最佳 checkpoint 在 epoch 20)，需要更長訓練或更高的  $\lambda_{\text{ctqw}}$ 。
- ENAQT 對三個蛋白質無差別改善，因  $\gamma$  需求衝突。

## 8 難以成藥蛋白質的三層驗證框架

對真正難以成藥的蛋白質 (僅 apo 結構)，建議以下三層驗證策略：




圖 6: 三層驗證框架。候選別構口袋必須通過幾何層 (Layer 1)、動力學層 (Layer 2) 和演化層 (Layer 3) 的篩選。隱性口袋 (apo 結構中不可見) 需繞過 Layer 1, 使用 MDpocket。

**Layer 1 —幾何 (Geometry):** 使用 fpocket 或 DoGSiteScorer 識別體積  $> 300 \text{ \AA}^3$ 、可成藥性評分  $> 0.5$  的口袋。

**Layer 2 —動力學 (Dynamics):** ENM/PRS effectivity 高 (代表擾動傳播效果強), 同時 CTQW  $C[\text{active} \rightarrow i]$  高 (代表量子通訊樞紐)。

**Layer 3 —演化 (Evolution):** ConSurf 保守性分數高, EVCouplings 顯示與活性位點殘基的共同演化。

**隱性口袋 (Cryptic Pocket):** apo 結構中不可見, 需要分子動力學模擬 (MDpocket on 100 ns MD) 捕捉瞬態開口。

## 9 與 PocketMiner 的關聯及提議流程

PocketMiner [2] 使用在 MD 軌迹上訓練的 GVP-GNN, 從靜態 apo 結構預測隱性口袋開啓機率。關鍵: 它不使用 ENM, 而是直接學習靜態結構特徵到 MD 衍生口袋標籤的映射。




圖 7: 提議之完整流程。PocketMiner 識別隱性口袋位置；CTQW Hybrid 識別與活性位點通訊的位點；ENM/PRS 提供動力學驗證。三者的交集即為最終候選。

#### PocketMiner 與本方法的互補性：

- PocketMiner 回答「這裡有可能打開的口袋嗎？」（幾何可達性）
- CTQW Hybrid 回答「這個口袋能從活性位點量子通訊觸及嗎？」（別構通訊）
- ENM/PRS 回答「擾動活性位點會影響這裡嗎？」（傳統動力學驗證）

## 10 为什么 $T \rightarrow \infty$ 連通性損失失效——量子行走根本原因分析

**核心推導：**  $C[i, j] = \sum_k |V_{ik}|^2 |V_{jk}|^2$  是 CTQW 的  $T \rightarrow \infty$  時間平均。由於  $\sum_j C[i, j] = 1$ （列和為 1）且蛋白質圖特徵向量是非局域化的：

$$C[i, j] \approx \frac{1}{N} \quad \text{for all } j \quad (N \sim 300-500)$$

對 BCR-ABL1 ( $N \approx 470$ )，實測：  $C[\text{act}, \text{allo}] = 0.00182$ ，  $C[\text{act}, \text{bg}] = 0.00199$ ，訊號比 =  $0.91 \times$ （訊號倒置！）。

修正方案——最優時間量子概率  $P(j, t^*)$ :

$$P(j, t^*) = \left| \langle j | e^{-iHt^*} | \text{active} \rangle \right|^2$$

$t^*$  是可學習參數 ( $t^* = e^{\log t^*}$ ), 梯度路徑為  $\mathcal{L} \rightarrow P(j, t^*) \rightarrow t^* \rightarrow \frac{\partial}{\partial t^*} e^{-iHt^*}$ .  
在玩具路徑圖 ( $N = 30$ ) 上的比較:

| 方法                                   | 識別比 (allo/bg) | 说明         |
|--------------------------------------|---------------|------------|
| $T \rightarrow \infty$ 連通性 $C[i, j]$ | 1.5×          | 接近 1, 無法識別 |
| $P(j, t^*)$ (本方法)                    | 32×           | 11 倍峰值信號放大 |

## 11 新架構提案: LLM + PDB + GVP-GNN + CTQW




圖 8: 提案之完整流程。ESM-2 提供每殘基 480 維語言模型嵌入 (免費本地推理); GVP-GNN 輸出哈密頓量  $H$ ; CTQW 以最優時間概率  $P(j, t^*)$  做推論。分數 =  $\alpha \cdot \sigma(\text{logits}) + \beta \cdot P(j, t^*)$ 。

為何引入 ESM-2 (LLM) ?

- 跨蛋白泛化: ESM-2 的進化背景讓模型能推論訓練集之外的蛋白質
- 不可成藥偵測: 內源無序蛋白在 ESM-2 空間有特殊模式, 可讓模型降低其權重

- 無需 API 費用：ESM-2 可本地運行 (fair-esm 或 HuggingFace)，不需商業 API

**PDB 中可直接取得的標注特徵 (免費)：** B-factor (熱運動)，DSSP 二級結構，已知活性位點 (UniProt 注释)，序列保守性。

## 12 評估框架：AUPRC 與多指標分析

**為何用 AUPRC 而非 AUROC ?** 別構殘基占全蛋白比例僅  $\sim 3-5\%$  (稀有正例), AUROC 對稀有類別不敏感 (隨機模型 AUROC  $\approx 0.5$ , 差模型仍可達 0.85)。AUPRC 的隨機基线 = 患病率  $\approx 0.04$ 。

| 模型                         | KRAS AUPRC | BCR-ABL1 AUPRC | Cardiac AUPRC | 平均           | Hit@5        |
|----------------------------|------------|----------------|---------------|--------------|--------------|
| $T \rightarrow \infty$ 連通性 | 0.611      | 0.051          | 0.358         | 0.340        | 0.533        |
| $P(j, t^*)$ 最優時間           | 0.914      | <b>0.764</b>   | 0.917         | <b>0.865</b> | <b>1.000</b> |
| 隨機基线                       | 0.050      | 0.038          | 0.029         | 0.039        | 0.039        |

**表 4:** BCR-ABL1 是最困難的情況： $T \rightarrow \infty$  連通性 AUPRC 僅 0.051 (接近隨機)， $P(j, t^*)$  方法將其提升至 0.764。AUPRC 放大倍數： $0.340 \rightarrow 0.865$ 。

評估指標完整定義：

**AUPRC** 精確率-召回率曲線下面積，對稀有正例最敏感 (主要指標)

**AUROC** ROC 曲線下面積，表示隨機對中的排序能力

**Hit@K** Top- $K$  預測殘基中命中真實別構位點的比率 (8 Å 半徑)

**EF10%** 富集因子：Top-10% 命中數 / 隨機期望命中數

**MCC** Matthews 相關系數：平衡精確率與召回率的單一指標

## 13 結論

| 發現                                     | 意涵                                   |
|----------------------------------------|--------------------------------------|
| <b>GVP 基准 (0.933) 勝過所有 CTQW 變體</b>     | 每節點 BCE 提供比連通性損失更密集的梯度訊號             |
| <b>連通性損失 <math>\gg</math> 機率損失</b>     | 封閉形式 $C[i, j]$ 避免了 100 步時間循環與梯度消失    |
| <b>ENAQT: <math>\gamma</math> 無法泛化</b> | 近口袋與遠口袋蛋白質需要相互衝突的去相干尺度               |
| <b>Hybrid 達到 0.867</b>                 | 結合 BCE 監督與 CTQW 物理先驗，優於單獨使用任一方法      |
| <b>BCR-ABL1 需要 CTQW</b>                | $> 30 \text{ \AA}$ 的別構口袋無法僅靠局部化學識別達到 |
| <b>PocketMiner + CTQW 互補</b>           | 幾何可開啟性 $\times$ 別構通訊 = 最強驗證          |

**後續步驟：** (1) 延長 Hybrid 訓練，使 BCR-ABL1 恢復至 1.00；(2) 將 PocketMiner 分數作為額外節點特徵整合至 GVP 編碼器；(3) 對真正難以成藥靶點（如 KRAS<sup>G12D</sup> 無共價彈頭位點）應用完整三層驗證框架。

訓練資料集：ASD Release 2019 (123 個蛋白質)。所有模型在 NVIDIA H200 上訓練 (Cleveland Clinic HPC, 帳號 GOV114009)。

程式碼：<https://github.com/leo07010/ctqw-allosteric-prediction>

## 参考文献

- [1] Jing, B., et al. (2021). *Learning from Protein Structure with Geometric Vector Perceptrons*. ICLR 2022.
- [2] Meller, A., et al. (2023). *Predicting the locations of cryptic pockets from single protein structures using the PocketMiner graph neural network*. *Nature Communications*, 14, 1177.
- [3] Rebentrost, P., et al. (2009). *Environment-Assisted Quantum Transport*. *New Journal of Physics*, 11, 033003.