

基於連續時間量子行走的蛋白質別構口袋預測

Cleveland Clinic Challenge 2026 — 技術報告

Leo

2026 年 6 月

目录

1 問題定義	1
2 核心假設與整體流程	2
3 GVP-GNN 架構	2
4 損失函數演進	4
5 ENAQT 失敗分析	4
6 混合模型 (Hybrid)	5
7 實驗結果	6
8 難以成藥蛋白質的三層驗證框架	6
9 與 PocketMiner 的關聯及提議流程	7
10 結論	9

1 問題定義

給定蛋白質的 **apo** (未結合) 晶體結構，預測哪些殘基構成**別構口袋** (allosteric pocket) ——一個能在不阻擋活性位點的情況下，遠程調節蛋白質功能的結合位點。

挑戰蛋白質：

蛋白質	Apo PDB	別構配體	相關性
KRAS G12C	4OBE	Sotorasib (6OIM)	致癌 RAS, switch-II 口袋
BCR-ABL1	1OPL	Asciminib (5MO4)	白血病激酶, 肉豆蔻鹽口袋
Cardiac Myosin	5TBY	Mavacamten (6C1H)	肥厚型心肌病

BCR-ABL1 的肉豆蔻醯口袋距 ATP 結合活性位點超過 30 Å，使用傳統擴散方法無法觸及。

2 核心假設與整體流程

核心假設：量子行走比傳統隨機行走更能捕捉蛋白質中的遠程通訊，原因是量子干涉使訊號可以同時沿多條路徑傳播，對長距離口袋（如 BCR-ABL1）尤其有利。




圖 1: 整體預測流程。GVP-GNN 編碼器同時輸出哈密頓量 H （用於 CTQW）和直接分類 logits（用於 BCE 損失）。推論時，混合模型以可調參數 β 合并兩種訊號。

3 GVP-GNN 架構

Geometric Vector Perceptron (GVP) [1] 是一種幾何等變圖神經網路，可同時處理純量特徵與向量特徵。

圖的建構：以 12 Å 截止距離建立 $C\alpha$ 接觸圖；每個節點帶有 24 維純量特徵（化學性質）和 1 組 3D 向量特徵（局部幾何）；每條邊帶有 24 維純量特徵（距離、方向）。




圖 2: GVP-GNN 架構。4 層訊息傳遞後，節點嵌入 $s \in \mathbb{R}^{N \times 64}$ 分叉至兩個輸出頭：H 頭產生 CTQW 哈密頓量；分類頭產生 BCE logits。

CTQW 連通性矩陣 (communicability):

$$C[i, j] = \sum_k |V_{ik}|^2 |V_{jk}|^2$$

其中 V 为 H 的特徵向量矩陣。此式为 $T \rightarrow \infty$ 時量子行走的時間平均，透過單次 `eigh` 呼叫即可封閉形式計算。

4 損失函數演進




圖 3: 從 v1 (稀疏 H) 到基准模型 (BCE) 的模型演進與命中率 (hit rate) 變化。圓形徽章顯示各模型在三個挑戰蛋白質上的平均命中率。

模型版本	主要改動	損失類型	命中率
CTQW v1	稀疏 H (相鄰矩陣)	連通性損失	0.533
CTQW v2	稠密 H ($hh^T/K + \text{diag}$)	連通性損失	0.800
CTQW v3	稠密 H + ENAQT 速率	ENAQT 損失	0.800
CTQW v4	每蛋白質可學習 γ	ENAQT 損失	0.800
Hybrid	共享編碼器 + 兩個輸出頭	BCE + 連通性	0.867
Baseline	純 GVP 分類	BCE	0.933

表 1: 各模型結果比較。黃色高亮為本研究提出之最佳量子增強方法。

基准模型 (0.933) 勝出的原因: BCE 損失對 N 個殘基提供密集梯度訊號；連通性損失每步僅產生 1 個純量梯度，訊號密度相差 N 倍 ($N \approx 200-500$)。

5 ENAQT 失敗分析

環境輔助量子輸運 (ENAQT, Haken–Strobl–Reineker 速率):

$$k_{ij} = \frac{2|H_{ij}|^2 \gamma}{\gamma^2 + (H_{ii} - H_{jj})^2}$$

此公式無需特徵分解，梯度路徑更直接： $\mathcal{L} \rightarrow p \rightarrow W \rightarrow K \rightarrow H_{ij}$ 。




圖 4: ENAQT 失敗根本原因：近口袋蛋白質（KRAS、Cardiac Myosin）需要高去相干速率（ $\gamma \approx 0.8$ ），遠口袋蛋白質（BCR-ABL1）需要近相干極限（ $\gamma \approx 0.05$ ）。共享的 γ 頭學到折衷值 $\gamma \approx 0.17$ ，導致兩者表現均差。

6 混合模型 (Hybrid)




圖 5: 混合模型架構。訓練時： $\mathcal{L} = \mathcal{L}_{\text{BCE}} + \lambda \cdot \mathcal{L}_{\text{comm}}$ 。推論時：scores = $\sigma(\text{logits}) + \beta \cdot C[\text{active} \rightarrow i]$ 。

設計原理：BCE 提供密集梯度使模型學習別構位點的化學特徵；CTQW 連通性在推論時加強那些既具化學相似性、又能從活性位點量子可達的殘基。

β 掃描結果：

β	KRAS	BCR-ABL1	Cardiac Myosin
0.0 (純 BCE)	1.00	0.60	0.80
0.2	1.00	0.60	1.00
0.5	1.00	0.60	1.00
1.0	1.00	0.60	0.80

表 2: β 對各蛋白質命中率的影響。BCR-ABL1 停留於 0.60，原因是最佳 checkpoint 在第 20 epoch (H 尚未完全收斂)。

7 實驗結果

模型	KRAS	BCR-ABL1	Cardiac	平均
CTQW v1 (稀疏 H)	0.80	0.40	0.40	0.533
CTQW v2 (稠密 H)	1.00	0.80	0.60	0.800
CTQW v3 (ENAQT)	0.80	0.80	0.80	0.800
CTQW v4 (per- γ)	1.00	0.80	0.60	0.800
Hybrid ($\beta = 0.5$)	1.00	0.60	1.00	0.867
Baseline (GVP BCE)	1.00	1.00	0.80	0.933

表 3: 三個挑戰蛋白質上的命中率 (Top-5, 距離閾值 8 Å)。黃色行為最佳量子增強結果。

關鍵發現：

- GVP BCE 基準達到 0.933，超越所有 CTQW 變體，原因是密集梯度訊號。
- 混合模型 (0.867) 使 Cardiac Myosin 從 0.60 提升至 1.00，顯示 CTQW 對近距離口袋有效。
- BCR-ABL1 在混合模型中停留於 0.60 (最佳 checkpoint 在 epoch 20)，需要更長訓練或更高的 λ_{ctqw} 。
- ENAQT 對三個蛋白質無差別改善，因 γ 需求衝突。

8 難以成藥蛋白質的三層驗證框架

對真正難以成藥的蛋白質 (僅 apo 結構)，建議以下三層驗證策略：




圖 6: 三層驗證框架。候選別構口袋必須通過幾何層 (Layer 1)、動力學層 (Layer 2) 和演化層 (Layer 3) 的篩選。隱性口袋 (apo 結構中不可見) 需繞過 Layer 1, 使用 MDpocket。

Layer 1 —幾何 (Geometry): 使用 fpocket 或 DoGSiteScorer 識別體積 $> 300 \text{ \AA}^3$ 、可成藥性評分 > 0.5 的口袋。

Layer 2 —動力學 (Dynamics): ENM/PRS effectivity 高 (代表擾動傳播效果強), 同時 CTQW $C[\text{active} \rightarrow i]$ 高 (代表量子通訊樞紐)。

Layer 3 —演化 (Evolution): ConSurf 保守性分數高, EVCouplings 顯示與活性位點殘基的共同演化。

隱性口袋 (Cryptic Pocket): apo 結構中不可見, 需要分子動力學模擬 (MDpocket on 100 ns MD) 捕捉瞬態開口。

9 與 PocketMiner 的關聯及提議流程

PocketMiner [2] 使用在 MD 軌迹上訓練的 GVP-GNN, 從靜態 apo 結構預測隱性口袋開啓機率。關鍵: 它不使用 ENM, 而是直接學習靜態結構特徵到 MD 衍生口袋標籤的映射。




圖 7: 提議之完整流程。PocketMiner 識別隱性口袋位置；CTQW Hybrid 識別與活性位點通訊的位點；ENM/PRS 提供動力學驗證。三者的交集即為最終候選。

PocketMiner 與本方法的互補性：

- PocketMiner 回答「這裡有可能打開的口袋嗎？」（幾何可達性）
- CTQW Hybrid 回答「這個口袋能從活性位點量子通訊觸及嗎？」（別構通訊）
- ENM/PRS 回答「擾動活性位點會影響這裡嗎？」（傳統動力學驗證）

10 結論

發現	意涵
GVP 基准 (0.933) 勝過所有 CTQW 變體	每節點 BCE 提供比連通性損失更密集的梯度訊號
連通性損失 $\gg$ 機率損失	封閉形式 $C[i, j]$ 避免了 100 步時間循環與梯度消失
ENAQT: γ 無法泛化	近口袋與遠口袋蛋白質需要相互衝突的去相干尺度
Hybrid 達到 0.867	結合 BCE 監督與 CTQW 物理先驗，優於單獨使用任一方法
BCR-ABL1 需要 CTQW	$> 30 \text{ \AA}$ 的別構口袋無法僅靠局部化學識別達到
PocketMiner + CTQW 互補	幾何可開啟性 $\times$ 別構通訊 = 最強驗證

後續步驟： (1) 延長 Hybrid 訓練，使 BCR-ABL1 恢復至 1.00；(2) 將 PocketMiner 分數作為額外節點特徵整合至 GVP 編碼器；(3) 對真正難以成藥靶點（如 KRAS^{G12D} 無共價彈頭位點）應用完整三層驗證框架。

訓練資料集：ASD Release 2019 (123 個蛋白質)。所有模型在 NVIDIA H200 上訓練 (Cleveland Clinic HPC, 帳號 GOV114009)。

程式碼：<https://github.com/leo07010/ctqw-allosteric-prediction>

参考文献

- [1] Jing, B., et al. (2021). *Learning from Protein Structure with Geometric Vector Perceptrons*. ICLR 2022.
- [2] Meller, A., et al. (2023). *Predicting the locations of cryptic pockets from single protein structures using the PocketMiner graph neural network*. *Nature Communications*, 14, 1177.
- [3] Rebentrost, P., et al. (2009). *Environment-Assisted Quantum Transport*. *New Journal of Physics*, 11, 033003.